

本节内容

IEEE 754 浮点数

表示范围

&

几种特殊状态

本节总览

IEEE 754 浮点数的表示范围

规格化浮点数的表示范围

超出规格化浮点数表示范围怎么办？

几种特殊状态：阶码全0、阶码全1

IEEE 754: 规格化浮点数、特殊状态的浮点数

规格化浮点数解读方法:

- 符号: 0正1负
- 阶码: 真值 = 按无符号整数解读阶码, 再减偏置值
- 尾数: 小数点前面隐含一个 1

IEEE 754 标准规定:

仅当阶码不全为0、也不全为1时, 表示这是一个“规格化浮点数”

阶码全为0、全为1 留作特殊用途, 需要按照特殊的方式去解读真值



float: 32位单精度浮点数

float 阶码偏置值 127



double: 64位双精度浮点数

double 阶码偏置值 1023

特殊状态的浮点数（阶码全0 或 全1）

值的类型	单精度 float (32位)				双精度 double (64位)			
	符号	阶码	尾数	值	符号	阶码	尾数	值
正零	0	全0	全0	+0	0	全0	全0	+0
负零	1	全0	全0	-0	1	全0	全0	-0
非规格化正数	0	全0	$f \neq 0$	$2^{-126}(0.f)$	0	全0	$f \neq 0$	$2^{-1022}(0.f)$
非规格化负数	1	全0	$f \neq 0$	$-2^{-126}(0.f)$	1	全0	$f \neq 0$	$-2^{-1022}(0.f)$
正无穷大	0	全1	全0	$+\infty$	0	全1	全0	$+\infty$
负无穷大	1	全1	全0	$-\infty$	1	全1	全0	$-\infty$
无定义数 (非数)	0或1	全1	$f \neq 0$	NaN	0或1	全1	$f \neq 0$	NaN



慌

阶码全为0、全为1 留作特殊用途，需要按照特殊的方式去解读真值




IEEE 754: 规格化浮点数的表示范围



注意！注意！

⚠注意：规格化浮点数的阶码不全为0、也不全为1

单精度
float 型



规格化尾数 → 1.XXXXXXXXXXXXXXXXXXXXXXXXXX

移码转真值：先按“无符号整数”解读阶码二进制串，再减掉偏置值，得到真值

先按无符号数解读阶码e，则取值范围为 1~254

减掉偏置值 127

阶码的真值取指范围为 -126 ~ 127

⚠注意: 规格化浮点数的阶码不全为0、也不全为1

单精度
float 型

8 bit

23 bit

阶码 e

尾数 f

规格化尾数 $\rightarrow 1.XXXXXXXXXXXXXXXXXXXXXX$

阶码的真值取指范围为 $-126 \sim 127$

【符,阶,尾】

1,11111110,11...11

1,000000001,00...00

0,00000001,00...00

0, 11111110, 11...11

二进制“科学计数法”

$$-1.11111111111111111111111111111111 \times 2^{127}$$
$$-1.0 \times 2^{-126}$$
 $+1.0 \times 2^{-126}$
$$+ 1.111111111111111111111111111111 \times 2^{127}$$

可表示的负数

零

可表示的正数

规格化浮点数

规格化浮点数

数轴

十进制→


$$-(2 - 2^{-23}) \times 2^{127}$$
$$-1.0 \times 2^{-126}$$
$$+1.0 \times 2^{-126}$$
$$+(2 - 2^{-23}) \times 2^{127}$$

14. IEEE 754 单精度浮点格式表示的数中, 最小的规格化正数是 ()。

- D. 1.0×2^{-149}



IEEE 754: 浮点数的上溢 (Overflow)



运算结果大于最大规格化正数时称为正上溢，小于绝对值最大的规格化负数时称为负上溢。
正上溢、负上溢 统称上溢 (Overflow)，也会翻译为“溢出”

浮点数上溢 (溢出) 的处理：

- ① 浮点数运算部件将运算结果设为设置为 $+\infty$ 或 $-\infty$
- ② 设置浮点数溢出异常标志位 (例如：x86会将浮点运算单元FPU的OE标志位 Overflow Exception 置为1)

注：IEEE 754 规定，默认不响应浮点数溢出异常，不中断程序；除非程序员手动开启此类异常响应

IEEE 754: 无穷大的表示

值的类型	单精度 float (32位)				双精度 double (64位)			
	符号	阶码	尾数	值	符号	阶码	尾数	值
正无穷大	0	全1	全0	$+\infty$	0	全1	全0	$+\infty$
负无穷大	1	全1	全0	$-\infty$	1	全1	全0	$-\infty$

float $\longrightarrow$

$+\infty$	0 11111111 000000000000000000000000	0x7F800000
$-\infty$	1 11111111 000000000000000000000000	0xFF800000

double $\longrightarrow$?

【程序示例】两个最大规格化正浮点数相加发生上溢

```
#include <stdio.h>
#include <float.h>
#include <math.h>
```

```
int main() {
    // float 类型最大有限值 (规格化正数)
    float max_float = FLT_MAX;
    printf("最大规格化正浮点数: %e\n", max_float);
```

```
    // 两个最大规格化正浮点数相加
    float result = max_float + max_float;
    printf("两个最大规格化正浮点数相加的结果: %e\n", result);
```

```
    // 检测是否为无穷大
    if (isinf(result)) {
        printf("结果为无穷大 (发生了上溢) \n");
    } else {
        printf("结果是有限数\n");
    }
}
```

```
return 0;
```

```
}
```

0,11111110,11...11

$+\infty$ 0,11111111,00...00

程序员可手动检查浮点数运算结果是否溢出，也可选择忽视溢出

$+(2 - 2^{-23}) \times 2^{127}$

运行结果

最大规格化正浮点数: 3.402823e+38

两个最大规格化正浮点数相加的结果: inf


结果为无穷大 (发生了上溢)

infinity | BrE m'fɪnɪti, AmE m'fɪnədi |

noun

- ① uncountable (boundlessness) 无限 wúxiàn
- ② uncountable (infinite distance) 无限远的距离 wúxiàn yuǎn de jùlí
 - into infinity 至无限远
- ③ uncountable Photography 无限远聚焦区 wúxiàn yuǎn jùjiāoqū
- ④ uncountable Mathematics 无穷大 wúqióngdà
 - to infinity 直至无穷
- ⑤ countable (huge, endless amount) 无限大的量 wúxiàndà de liàng
 - an infinity of sth; 数不清的某物

IEEE 754: 浮点数的下溢 (Underflow)




若浮点数运算结果在 0 至绝对值最小的规格化正数之间时称为正下溢，在 0 至绝对值最小规格化负数之间时称为负下溢。正下溢和负下溢统称下溢 (Underflow)

浮点数运算结果下溢时的处理：

- ① 若结果落入非规格化区间 $\rightarrow$ 用非规格化浮点数存储；若结果太小（真值逼近于0） $\rightarrow$ 按机器零存储
- ② 若下溢至机器零，设置浮点数下溢异常标志位（例如：x86会将FPU的UE标志位 Underflow Exception 置1）

注：IEEE 754 规定，默认不响应浮点数下溢异常，不中断程序；除非程序员手动开启此类异常响应

IEEE 754: 浮点数的下溢 (Underflow)



浮点数运算结果下溢时的处理:

- ① 若结果落入非规格化区间 $\rightarrow$ 用非规格化浮点数存储；若结果太小（真值逼近于0） $\rightarrow$ 按机器零存储
- ② 若下溢至机器零，设置浮点数下溢异常标志位（例如：x86会将FPU的UE标志位 Underflow Exception 置1）

注：IEEE 754 规定，默认不响应浮点数下溢异常，不中断程序；除非程序员手动开启此类异常响应

IEEE 754: 真值0 的表示

值的类型	单精度 float (32位)				双精度 double (64位)			
	符号	阶码	尾数	值	符号	阶码	尾数	值
正零	0	全0	全0	+0	0	全0	全0	+0
负零	1	全0	全0	-0	1	全0	全0	-0

float →

+0

0 00000000 000000000000000000000000

0x00000000

-0

1 00000000 000000000000000000000000

0x80000000

double →

?

IEEE 754: 非规格化浮点数的表示

值的类型	单精度 float (32位)				双精度 double (64位)			
	符号	阶码	尾数	值	符号	阶码	尾数	值
非规格化正数	0	全0	$f \neq 0$	$2^{-126}(0.f)$	0	全0	$f \neq 0$	$2^{-1022}(0.f)$
非规格化负数	1	全0	$f \neq 0$	$-2^{-126}(0.f)$	1	全0	$f \neq 0$	$-2^{-1022}(0.f)$



不可以将阶码解读为 $0 - 127 = -127$ ，而是固定解读为阶码的最小真值 -126

尾数按照 $0.xxxxxx...xxx$ 解读。即 小数点前隐含0，而不是隐含1

float 非规格化正数示例 $\longrightarrow$ 0 00000000 010000000000000000000000 $\longrightarrow$ 真值 = $0.01 \times 2^{-126} \rightarrow = 2^{-128}$

绝对值最小的 float 非规格化正数 $\longrightarrow$ 0 00000000 000000000000000000000001
真值 = $0.000000000000000000000001 \times 2^{-126} \rightarrow = 2^{-149}$

绝对值最大的 float 非规格化正数 $\longrightarrow$ 0 00000000 111111111111111111111111
真值 = $0.111111111111111111111111 \times 2^{-126} \rightarrow = (1 - 2^{-23}) \times 2^{-126} = 2^{-126} - 2^{-149}$

IEEE 754: 非规格化浮点数的表示

值的类型	单精度 float (32位)				双精度 double (64位)			
	符号	阶码	尾数	值	符号	阶码	尾数	值
非规格化正数	0	全0	$f \neq 0$	$2^{-126}(0.f)$	0	全0	$f \neq 0$	$2^{-1022}(0.f)$
非规格化负数	1	全0	$f \neq 0$	$-2^{-126}(0.f)$	1	全0	$f \neq 0$	$-2^{-1022}(0.f)$



不可以将阶码解读为 $0 - 127 = -127$ ，而是固定解读为阶码的最小真值 -126

尾数按照 $0.xxxxxx...xxx$ 解读。即 小数点前隐含0，而不是隐含1

float 非规格化负数示例 $\longrightarrow$ 1 00000000 010000000000000000000000 $\longrightarrow$ 真值 = $-0.01 \times 2^{-126} \rightarrow = -2^{-128}$

绝对值最小的 float 非规格化负数 $\longrightarrow$ 1 00000000 000000000000000000000001
真值 = $-0.000000000000000000000001 \times 2^{-126} \rightarrow = -2^{-149}$

绝对值最大的 float 非规格化负数 $\longrightarrow$ 1 00000000 111111111111111111111111
真值 = $-0.111111111111111111111111 \times 2^{-126} \rightarrow = -(1 - 2^{-23}) \times 2^{-126} = -(2^{-126} - 2^{-149})$

【真题训练】2023年真题_14

【2023真题_14】

14. 已知 float 型变量用 IEEE 754 单精度浮点数格式表示。若 float 型变量 x 的机器数为 8020 0000H, 则 x 的值是 ()。

A. -2^{-128}

B. -1.01×2^{-127}

C. -1.01×2^{-126}

D. 非数 (NaN)

0x80200000

= 1000 0000 0010 0000 0000 0000 0000 0000

= 1,00000000,010000000000000000000000

↑

阶码全0

↑

尾数不全为0



你是谁啊

非规格化浮点数真值 = $-0.01 \times 2^{-126} = -2^{-128}$

IEEE 754: 非数 (NaN) 的表示

值的类型	单精度 (32位)				双精度 (64位)			
	符号	阶码	尾数	值	符号	阶码	尾数	值
无定义数 (非数)	0或1	全1	$f \neq 0$	NaN	0或1	全1	$f \neq 0$	NaN

在 IEEE 754 浮点数标准中: **NaN** 代表 “不是一个数” (Not a Number)

float NaN示例 $\longrightarrow$ 0 11111111 10000000001110000000001

运算结果为 NaN 的典型例子:

- 0除以0
- 负数开根号
- 无穷减无穷

```
0.0f / 0.0f           // NaN
sqrt(-1.0f)           // NaN
 $\infty - \infty$        // NaN
```

sqrt 函数用于计算一个数的平方根
#include <math.h>

特别地:

- 非零数值除以0

```
1.0f / 0.0f;          // + $\infty$ 
-1.0f / 0.0f;         // - $\infty$ 
```

IEEE 754 规定, 非零数值除以0,
结果是无穷, 0除以0结果是NaN

【程序示例】运算结果为 NaN、 ∞ 的例子

```
#include <stdio.h>
#include <math.h>
```

```
int main() {
    float a = 0.0f;
    float b = 0.0f;
    float result = a / b;

    printf("结果是: %f\n", result);
```

```
if (isnan(result)) {
```

判断是否为NaN

```
    printf("结果为 NaN\n");
```

```
} else {
```

```
    printf("结果不是 NaN\n");
```

```
}
```

```
return 0;
```

```
}
```

程序输出:
结果是: nan
结果为 NaN



```
#include <stdio.h>
#include <math.h>
```

```
int main() {
    float a = 1.0f;
    float b = 0.0f;
    float result = a / b;

    printf("结果是: %f\n", result);
```

```
if (isinf(result)) {
```

判断是否为 ∞

```
    printf("结果为无穷大\n");
```

```
} else {
```

```
    printf("结果是有限数\n");
```

```
}
```

```
return 0;
```

```
}
```

程序输出:
结果是: inf
结果为 无穷大

IEEE 754 浮点数的表示范围

浮点数的表示范围

要点

规格化浮点数

特点：阶码不全为0、不全为1
尾数的小数点前隐含1
阶码真值 = 按无符号数解读阶码 - 偏置值


非规格化浮点数

特点：阶码全0，尾数不全为0
尾数小数点前隐含0
阶码真值 = 1 - 偏置值

其他特殊状态

± 0 、 $\pm \infty$ 、NaN

命题：推演各特殊值



阶码全0、全1的解释

值的类型	单精度 float (32位)				双精度 double (64位)			
	符号	阶码	尾数	值	符号	阶码	尾数	值
正零	0	全0	全0	+0	0	全0	全0	+0
负零	1	全0	全0	-0	1	全0	全0	-0
非规格化正数	0	全0	$f \neq 0$	$2^{-126}(0.f)$	0	全0	$f \neq 0$	$2^{-1022}(0.f)$
非规格化负数	1	全0	$f \neq 0$	$-2^{-126}(0.f)$	1	全0	$f \neq 0$	$-2^{-1022}(0.f)$
正无穷大	0	全1	全0	$+\infty$	0	全1	全0	$+\infty$
负无穷大	1	全1	全0	$-\infty$	1	全1	全0	$-\infty$
无定义数 (非数)	0或1	全1	$f \neq 0$	NaN	0或1	全1	$f \neq 0$	NaN

超出规格化浮点数表示范围如何处理？

上溢（溢出）的处理

- ① 将结果设置为 $+\infty$ 或 $-\infty$ （视符号位而定）
- ② 设置浮点数溢出异常标志位（IEEE 754 默认不响应浮点数溢出异常，不中断程序）


下溢的处理

- ① 若结果落入非规格化区间 → 用非规格化浮点数存储；若结果太小（真值逼近于0）→ 按机器零存储
- ② 若下溢至机器零，设置浮点数下溢异常标志位（IEEE 754 默认不响应浮点数下溢异常，不中断程序）

【课后训练】推演 double 的表示范围

【符,阶,尾】

二进制“科学计数法”



double型结构 = 1+11+52 bit 【符号,阶码,尾数】，阶码偏置值 1023

【课后训练】写出 double 的 ± 0 、 $\pm \infty$ 、NaN



double型结构 = 1+11+52 bit 【符号,阶码,尾数】，阶码偏置值 1023

double ± 0 →	+0	0 00000000000 000.....000 (52bit 0)	0x0000000000000000
	-0	1 00000000000 000.....000 (52bit 0)	0x8000000000000000
double $\pm \infty$ →	$+\infty$	0 11111111111 000.....000 (52bit 0)	0x7FF0000000000000
	$-\infty$	1 11111111111 000.....000 (52bit 0)	0xFFF0000000000000
double NaN →		0 11111111111 XXX.....XXX (52bit不全为 0)	
		1 11111111111 XXX.....XXX (52bit不全为 0)	